

DexGraspVLA: 一种面向通用灵巧抓取的视觉-语言-动作框架

Yifan Zhong^{1,2*}, Xuchuan Huang^{1,2*}, Ruochong Li^{2,3}, Ceyao Zhang^{1,2}, Yitao Liang^{1,2}, Yaodong Yang^{1,2†}, Yuanpei Chen^{1,2†}

¹研究所

对于人工智能, 北京大学, ²北大-普思博联合实验室, ³香港科技大学 (广州)



图 1 | 我们提出了 **DexGraspVLA**, 这是一种分层的视觉 - 语言 - 动作框架, 在“零样本”的真实世界环境中, 面对成千上万种未见过的物体、光照和背景组合, 其灵巧抓取的成功率达到了 90% 以上。

摘要

灵巧抓取在机器人领域一直是一个基础但具有挑战性的问题。通用机器人必须能够在各种场景中抓取不同类型的物体。然而, 现有的研究通常依赖于特定的假设, 比如单一物体的设置或有限的环境, 这导致了泛化能力受限。我们的解决方案是 DexGraspVLA, 这是一个分层框架, 它利用预训练的视觉语言模型作为高级任务规划器, 并学习基于扩散的策略作为低级动作控制器。关键在于通过迭代将多样化的语言和视觉输入转换为领域不变的表示, 从而减轻领域偏移, 使得模仿学习能够有效应用。因此, 它能够在广泛的现实场景中实现稳健的泛化。值得注意的是, 在“零样本”环境中, 面对数千种未见过的物体、光照和背景组合, 我们的方法实现了 90% 以上的成功率。

实证分析进一步证实了内部模型行为在不同环境变化中的一致性, 从而验证了我们的设计并解释了其泛化性能。我们希望我们的工作能够实现通用灵巧抓取迈进一步。我们的演示和代码可在 <https://dexgraspvla.github.io/> 找到。

1. 简介

灵巧的多指手作为通用的机器人末端执行器, 在各种操作任务中展现出了卓越的能力[1, 2, 3, 4, 5, 6, 7, 8, 9]。在这些能力中, 抓取是最基本的前提, 但也是最具挑战性的问题之一。现有的灵巧抓取方法主要是在孤立的物体或简化的设置下进行评估。然而, 实际应用需要更通用的解决方案。

开发能够在工业制造和家庭环境等各种场景中可靠运行的通用灵巧抓取能力。然而，开发通用灵巧抓取能力面临着多方面的挑战。在物体层面，策略必须能够适应各种物理特性，包括形状、质量、纹理和方向。除了物体特性之外，系统还必须对各种环境因素表现出强大的适应性，例如光照条件、背景复杂度以及潜在的干扰。更复杂的是，多物体场景会带来额外的复杂性，这需要更复杂的推理能力。例如，在杂乱或堆叠的环境中，规划出抓取所有物体的最佳顺序就成为一项关键的认知任务，而不仅仅是简单的抓取执行。

传统的灵巧抓取方法遵循两阶段流程：首先从单帧感知中预测目标抓取姿态，然后执行开环运动规划以达到该姿态[10, 11, 12]。然而，此类方法严重依赖于精确的相机校准和机械精度要求。端到端方法，如模仿学习和强化学习，通过根据实时感知反馈不断调整动作来实现闭环抓取，提供了更稳健和自适应的解决方案。近年来，强化学习在机器人系统中的应用取得了显著进展[13, 14, 15, 16]。借助大规模并行模拟，强化学习使机器人能够在模拟环境中进行大量训练，然后将学到的策略部署到现实世界中。尽管取得了这些进展，但现实世界物理参数的复杂性给模拟建模带来了重大挑战，导致不可避免的模拟与现实之间的差距。与此同时，研究人员探索了模仿学习方法来学习操作技能[17, 18, 19]。这些方法通过遥操作收集人类演示数据，并直接使用监督学习从原始感知输入学习到机器人控制指令的映射。然而，这类方法往往难以超越演示数据实现泛化。尽管通用抓取需要处理各种各样的物体和环境，但为所有情况收集演示数据是不切实际的。因此，关键挑战在于如何高效利用演示数据以实现更广泛的泛化。

视觉和语言基础模型的迅速兴起[20, 21, 22, 23, 24]为机器人操作带来了巨大的机遇。这些模型在预训练阶段利用了海量的互联网规模数据，展现出了对视觉和语言输入的出色

场景理解和泛化能力。为了将这些能力用于决策制定，研究人员探索了将视觉和语言基础模型整合到动作生成中的方法，从而开发出了视觉-语言-动作（VLA）模型。虽然一种直观的方法是直接让基础模型生成机器人控制指令[25, 26]，但这种简单策略存在根本性的局限性。由于其训练过程中缺乏物理交互数据，导致模型的空间智能有限。另一种方法是通过端到端的方式在机器人数据上训练视觉语言模型（VLM）[27, 28]。然而，这种范式通常需要大量手动收集的演示数据[29, 30]，以涵盖现实世界中的全部多样性和复杂性。即便如此，这些模型在未见过的场景中表现明显下降，仍需进一步收集数据并进行微调以应对新的情况。此外，机器人数据集与庞大的预训练语料库之间存在巨大差异，导致灾难性遗忘，损害了模型宝贵的长程推理能力。如何有效利用基础模型的世界知识来增强机器人策略的泛化能力，仍然是一个挑战。

在本文中，我们提出了 **DexGraspVLA**，这是首个用于通用灵巧抓取的分层视觉语言动作框架，它融合了基础模型和模仿学习的互补优势。在高层次上，它利用预训练的视觉语言模型作为任务规划器，对语言指令进行解释和推理，规划整体抓取任务，并提供监督信号。在这些信号和多模态输入的引导下，低层次的基于扩散的模块化控制器生成闭环动作序列。DexGraspVLA 的核心在于利用基础模型将多样化的视觉和语言输入迭代转换为领域不变的表示，然后高效且有效地应用基于扩散的模仿学习来捕捉我们灵巧抓取数据集中的动作分布。因此，训练集之外的新场景不再导致失败，因为基础模型将它们转换为类似于训练期间遇到的表示，从而仍处于学习策略的领域范围内。这种方法将基础模型丰富的世界知识与模仿学习强大的动作建模能力相融合，从而在实际应用中实现了稳健的泛化性能。

值得注意的是，DexGraspVLA 在杂乱场景中的抓取成功率达到了前所未有的 90.8%，涵盖了 1287 种未见过的物体、光照和背景情况。

在“零样本”环境中对所有地面组合进行了测试。在单目标抓取基准上的系统评估表明，DexGraspVLA 达到了 98.6% 的综合成功率，比直接从原始视觉输入中学习控制器的现有基线至少高出 48%。此外，我们的实证分析表明，DexGraspVLA 内部的表示和注意力图在不同环境中保持一致，从而证实了其框架设计并解释了其性能。这些结果证实，DexGraspVLA 能够从少量单领域的人类演示中有效学习，并可靠地推广到各种现实世界的情况，这是迈向通用灵巧抓取的有希望的一步。

2. 相关工作

2.1. 灵巧抓取

灵巧抓取通常分为两类：两阶段方法和端到端方法。两阶段方法首先生成抓取姿态，然后控制灵巧手朝向该姿态。主要的挑战在于根据视觉观察生成高质量的抓取姿态。当前的方法采用基于采样[31, 32]、基于优化[11, 12, 33, 34, 35, 36]或基于回归[37, 38]的方法来生成目标抓取姿态，随后进行机器人执行的运动规划。例如，SpringGrasp [10] 使用基于优化的方法来建模部分观测中的不确定性，从而提高抓取姿态生成的质量。UGG [39] 提出了一种基于扩散的方法，将抓取姿态和物体几何形状的生成统一起来。尽管这些方法得益于感知与控制的解耦以及模拟数据的生成，但它们通常缺乏闭环反馈，并且对干扰和校准误差敏感。

端到端方法直接使用模仿学习或强化学习来建模抓取轨迹。近期的研究探索了在模拟环境中使用强化学习训练灵巧操作，并将其迁移到现实世界[40, 1, 41, 2, 42, 43, 13, 14, 15, 16, 44, 3, 4, 5, 6, 7, 45, 46, 47, 48]。DexVIP [49] 和 GRAFF [50] 使用计算机视觉方法生成可操作性提示，并基于这些特征使用强化学习训练策略。DextrAH-G [51] 和 DextrAH-RGB [52] 通过在模拟环境中进行大规模并行训练，在现实世界中展示了一定的泛化能力。然而，这种对模拟环境的依赖不可避免地带来了模拟与现实之间的差距，而直接在现实世界中训练又存在样本效率低下的问题。最近，使用人类演示的模仿学习在复杂

任务中取得了显著成果[50, 53, 17, 18, 19, 54, 55, 56, 57, 58, 59, 60, 61, 62, 63, 64, 65, 66]。这些方法需要人类远端操作来收集演示数据，并直接学习数据集中的分布。虽然这种训练方式更容易，但其泛化能力受到限制。SparseDFF [67] 和神经注意力场 [68] 探索了如何通过 3D 蒸馏特征场来增强泛化能力。

2.2. 机器人基础模型

近年来，在大规模数据集上预训练的基础模型取得了显著进展。视觉基础模型（例如 SAM [23, 24]、DINO [69, 20]）展现出强大的分布外泛化能力，而包括 GPT-4o [22] 和 Qwen2.5-VL [70] 在内的视觉语言模型则具备复杂的多模态推理能力，甚至能够在游戏中执行任务 [71, 72]。有效利用这些基础模型已成为机器人研究的一个有前景的方向。一种突出的方法，以 RT-X [30]、OpenVLA [27]、Pi0 [28] 等为代表，是直接在机器人数据上对视觉语言模型进行微调。然而，这种策略需要大量涵盖各种现实条件的演示数据才能实现泛化。即便目前最大的机器人数据集 [29, 30, 28] 也未能涵盖所有场景；基于这些数据集训练的模型在未见过的领域仍表现不佳，通常还需要额外的数据收集和微调才能适应新环境。此外，由于机器人操作任务的复杂性和专门数据的稀缺性，这些模型往往牺牲了部分高级推理能力。另一条研究路线，以 VoxPoser [25] 和 Rekep [26] 为代表，利用视觉语言模型生成特定任务的输出，例如可操作性地图或约束点，然后将其与传统的运动规划相结合。虽然这种分层策略通常能保留视觉语言模型固有的推理能力，但它依赖于足够强大的低级控制器来执行高级指令，因此有效接口的设计至关重要。我们的工作利用预训练的基础模型生成领域不变的表示，这有助于学习灵巧的抓取策略。通过将大量现实世界的复杂性转移到基础模型上，我们可以显著减少所需的演示数据量，同时实现强大的零样本泛化能力。

3. 问题陈述

我们的目标是开发一种基于视觉的语言引导灵巧抓取控制策略，该策略的制定




图2 | 我们框架的概述。DexGraspVLA 采用分层架构，由现成的基于视觉语言模型（VLM）的高级规划器和基于扩散的低级控制器组成。对于杂乱的场景，规划器会根据用户提示（例如“清理桌子”）进行推理，在必要时将其分解为多个抓取指令。对于每个指令 L （例如“抓取饼干”），规划器会从头部图像 $I_h T_0$ 中识别目标物体 A ，并在初始时间 T_0 标记其边界框 $(X1A, Y1A, X2A, Y2A)$ 。控制器由四个部分组成：（1）两个分割模型，包括 SAM（在 T_0 时获取物体的掩码 m_{T_0} ）和 Cutie（一个视频分割模型，持续跟踪每个抓取过程中的掩码 m_t during）；（2）三个视觉编码器，包括两个冻结的 DINOv2，用于从第三视图图像 $I^t_{T_0}$ 和第一视图图像 I^w 中提取特征。

T 以及一个可训练的视觉变换器（ViT），用于处理掩码 m_t ；（3）三个多层感知机

投影器将视觉特征和机器人本体感受状态映射到相同的特征空间，形成特征序列；（4）一个扩散转换器（DiT）从 a_t 到 a_{T+H-1} 中预测动作块。在控制器抓取过程中，规划器会监控执行情况，检查抓取是否成功，并在失败时协助重新抓取。此过程会一直持续，直到用户提示完全完成。

作为一个顺序决策问题。最初，给出一个语言指令 L is, 例如“抓住玩具”，以直接指定目标物体。在每个时间步长 T ，策略 π receives 根据第一视图图像 $I^w T \in \mathbb{R}^{H \times W \times 3}$ 进行决策。

来自腕部相机（ H 和 W 分别表示图像的高度和宽度）的图像、来自头部相机的第三视图图像 $I^h_t \in \mathbb{R}^{H \times W \times 3}$ 以及由七个机械臂关节角度组成的机器人本体感知 $s_t \in \mathbb{R}^{13}$ $s^{arm}_t \in \mathbb{R}^7$

以及六个手部关节角度 s_t

手

属于实数集。条件 6

基于这些观察结果，机器人执行一个动作 $a_t =$ （手臂）

一只 $\in \mathbb{R}^{13}$ ，其中 a^{arm}_t 设 $\in \mathbb{R}^7$ 和 a_t

手

t

$hand T \in \mathbb{R}^6$ 分别表示臂和手的目标关节角度，通过从动作分布 $\pi(\cdot | (I^w J) T=0, (I^h J) T=0, (s J) T=0, L)$ 中采样得到。此过程持续进行，直至达到终止条件。机器人会收到一个二进制奖励 $R \in \{0, 1\}$ ，表明其是否完成了指令 L successfully。策略 π is 的目标是最大化期望奖励 EL ， $\{(I^w, I^h, s, J, a) | T(R)\}$ 。

$j=0$

更一般地说，我们考虑这样一种情况，即用户提示 p_{may} 是一个涉及长期任务的指令

多个抓取过程，例如“清理餐桌”。这需要策略 π_{to} 对提示进行推理，将其分解为单独的抓取指令 $\{L_i\}$ ，并依次完成。

4. 方法

本节介绍 DexGraspVLA，这是首个用于灵巧抓取的分层视觉语言动作（VLA）框架。我们将首先详细阐述 DexGraspVLA 框架（第 4.1 节），然后介绍我们的数据收集流程（第 4.2 节），这两者共同实现了灵巧抓取策略的训练。

4.1. DexGraspVLA 框架

如图 2 所示，DexGraspVLA 采用了一种分层且模块化的架构，由一个规划器和一个控制器组成。下面我们将解释每个部分的设计。

规划器。我们认识到，要实现通用灵巧抓取，模型需要能够处理多模态输入、进行视觉定位，并对用户提示进行推理。基于视觉语言模型（VLM）的最新进展，我们采用现成的预训练模型 Qwen-VL-Chat [75] 作为高级规划器，来概述和监控灵巧抓取的工作流程。给定用户提示 P ，规划器根据头部相机的观察结果推理执行计划。具体而言，如果 p_{is} 提示涉及多个抓取步骤的长时任务描述，例如“清理桌子”，规划器会考虑桌面上物体的位置和朝向，并提出一个合适的抓取指令 L_1 作为第一步，例如“抓取饼干”。否则，如果 $p_{directly}$ 只针对一个物体进行抓取，规划器则将其视为指令 L 。

对于每条指令 L ，规划器通过在初始时间步长 T_0 头部相机图像 I_{hT_0} 中标记目标对象的边界框 (X_1, Y_1, X_2, Y_2) 来引导低级控制器。尽管不同用户和场景的语言指令的措辞和内容可能多种多样且灵活多变，即表现出领域差异性，但边界框作为对象定位的格式始终如一，不受语言和视觉输入变化的影响，即实现了领域不变性。因此，这种转换减轻了控制器的学习难度。

控制器收到边界框后开始执行。在此过程中，规划器以每秒 1 次的频率查询当前头部图像来监控进度。如果发现机器人成功抓取了物体，规划器将执行预设的放置动作，将物体放入袋中，然后将机械臂和手复位到初始状态。之后

，规划器通过推理提示和其视野中剩余的物体来提出新的抓取指令 L_2 ，直到提示 p_{is} 完全完成。另一方面，如果控制器未能抓取目标物体，规划器将重置机器人，并根据当前物体状态重新初始化抓取循环，给出新的指令。

控制器。基于目标边界框 (X_1, Y_1, X_2, Y_2) ，控制器旨在杂乱环境中抓取目标物体。我们将此边界框作为输入提供给 SAM [23] 以获取目标物体的初始二值掩码 $m_0 \in \{0, 1\}^{H \times W \times 1}$ ，然后使用 Cutie [76] 随时间持续跟踪掩码，在每个时间步 t 生成 $m_{t,at}$ 。这确保了在整个过程中在杂乱场景中准确识别。问题在于有效地学习策略 π_{that} ，以对动作分布 $\pi(\cdot | I_w T, I_{Th}, sT, mT)$ 进行建模。

要实现通用灵巧抓取能力，该系统必须能在各种不同的现实场景中有效泛化。然而，原始视觉输入 I_w 的高度变异性

τ, I_{T} poses 一项基础的
学习任务关键表示的挑战。传统的模仿学习方法在物体或环境条件出现细微变化时往往会出现灾难性的失败。为了解决这个问题，我们的解决方案是再次将可能因领域变化而不同的输入转换为适合模仿学习的领域不变表示。我们认识到，尽管像素级感知可能差异很大，但大型基础模型提取的细粒度语义特征往往更稳健且更一致。这将在第 5.5 节中得到实证验证。因此，我们利用诸如 DINOv2 [20] 这样在互联网规模数据上进行过预训练的特征提取器从原始图像中获取特征。在每个时间步长 T ，我们获取头部相机图像特征。

$$z_t^h = \phi^h(I_t^h) \in \mathbb{R}^{L^h \times D^h},$$

以及腕部相机图像特征

$$z_t^w = \phi^w(I_t^w) \in \mathbb{R}^{L^w \times D^w},$$

其中 L^h 和 D^h 分别表示头部和手腕特征序列的长度和隐藏维度。正如我们在第 5.5 节中所展示的，这些提取的特征对于分散注意力的视觉因素具有相对的不变性。

到目前为止，原始语言和视觉输入，包括指令 L and 图像 I_w

τ, I_{T} 已经迭代
主动转换为领域不变的表示形式，包括掩码 m_t and 特征 z_t^h, z_t^w
 τ 通过
利用基础模型。这为模仿学习奠定了基础。我们现在学习策略 π_{that}

在这些表示上预测 $\mathbf{H}^{\text{conditioning}}$ 一个时间跨度为 $\mathbf{H}^{\text{conditioning}}$ 的动作块。

为了将对象掩码与头部相机特征融合，我们使用随机初始化的视觉变换器（ViT）投影头部图像特征空间，生成 $\mathbf{zm} \in \mathbb{R}^{L \times D}$ 。

然后将 $\mathbf{z}_T$ and $\mathbf{z}_T$ patch-wise 连接起来形成 $\mathbf{m}_h$

$$\mathbf{z}_t^h \in \mathbb{R}^{L^h \times 2D^h}.$$

随后，我们将 $\mathbf{z}_T^h$ 腕部相机的特征 $\mathbf{zw}$ 进行映射

将 (t) 以及机器人的状态 $\mathbf{s}_T$ into 嵌入到一个公共的嵌入空间中，使用单独的多层感知机（MLP），从而得到 $\mathbf{z}_{hT}$ 和 $\mathbf{z}_{wT}$ 。

这些嵌入随后被连接起来，以形成完整的观测特征序列。

$$\mathbf{z}_t^{\text{obs}} \in \mathbb{R}^{(1+L^h+L^w) \times D}.$$

对于动作预测，我们采用 DiT [77] 来生成多步动作，遵循扩散策略范式 [78, 79, 28]。具体来说，在每个时间步 T ，我们将下一个 $\mathbf{H}^{\text{actions}}$ 动作打包成一个块 $\mathbf{A}_T = \mathbf{a}_{T:T+H} = [\mathbf{a}_T, \mathbf{a}_{T+1}, \dots, \mathbf{a}_{T+H-1}]$ 。在训练过程中，随机抽取一个扩散步骤 $T^D = K$ ，并向 $\mathbf{A}_T$ 添加高斯噪声 ϵ ，从而得到带噪声的动作标记 $\mathbf{x}_K$ 形式上，

$$\mathbf{x}_k = \alpha_k \mathbf{A}_t + \sigma_k \epsilon,$$

其中 α_k and σ_k are 为标准 DDPM 系数。然后，我们将 DiT 与观测特征序列 $\mathbf{z}^{\text{obs}}$ T 一起输入 $\mathbf{x}_k$ into。每个 DiT 层对动作标记执行双向自注意力操作，对 $\mathbf{z}^{\text{obs}}$ T 执行交叉注意力操作，并进行 MLP 变换，最终预测原始噪声 ϵ 。通过最小化预测噪声与真实噪声之间的差异，模型学会重建真实动作片段 $\mathbf{A}_T$ 。在推理时，通过迭代去噪步骤从学习到的分布中恢复预期的多步动作序列，从而能够稳健地模仿复杂的长时行为。我们还采用了滚动时域控制策略，即在生成新的动作片段预测之前仅执行第一个动作片段 ϵ ，从而提高实时响应能力。

总体而言，DexGraspVLA 通过基础模型对来自不同领域输入的领域不变表示进行模仿学习。这种方法不仅利用了基础模型的世界知识和泛化能力，还有效地捕捉了从这些抽象表示到最终动作输出的映射。接下来，我们将讨论为 Dex-GraspVLA 训练提供动力的数据收集工作。

4.2. 数据收集

为了训练我们灵巧抓取的策略，我们手动收集了一个包含 2094 次成功抓取的训练数据集。




图 3 | 用于灵巧抓取的硬件平台。

在杂乱场景中抓取物体的多个片段。该数据集包含 36 种家居用品，涵盖了大小、重量、几何形状、纹理、材质和类别等广泛范围。每个片段 $\tau = \{(\mathbf{I}_T, \mathbf{I}_w$

$$T, \mathbf{s}_T, \mathbf{m}_T, \mathbf{a}_T)\}_{T=0}^T$$

记录原始相机图像 $\mathbf{I}_T$ ， $\mathbf{I}_T$ 以及机器人程序 $\mathbf{I}_T^{\text{hw}}$

每个时间步长 T 都有先验感知 $\mathbf{s}_T$ 、物体掩码 $\mathbf{m}_T$ 和动作 $\mathbf{a}_T$ 。掩码 $\mathbf{m}_T$ is 的标注方式与控制器中的相同。对于每个物体，我们将其放置在 3×3 网格中的九个位置，并在每个位置收集多个抓取演示。杂乱场景中的其他物体在不同回合中随机变化。这些演示以典型的人类动作速度进行，每个大约 3.5 秒。它们经过严格的人工检查以确保质量和可靠性。Dex-GraspVLA 控制器通过模仿学习在这个数据集上进行训练。

5. 实验

在本节中，我们将全面评估 DexGraspVLA 的性能。所有实验均在与演示设置不同的机器人和环境中进行。这种“零样本”设置从根本上比大多数先前的模仿学习研究更具挑战性，因为后者依赖于少量样本学习来实现高性能。我们的实验旨在回答以下问题：

1. DexGraspVLA 在杂乱场景中对成千上万种此前从未见过的物体、光照和背景组合的泛化效果如何？（第 5.2 节）
2. 与那些不使用冻结特征提取器而是直接从原始视觉输入中学习的基线方法相比，DexGraspVLA 的泛化优势如何？（第 5.3 节）




图 4 | (a) 在我们的实验中使用的未见过物体的一个代表性部分。总共，我们在 360 个未见过的物体上测试了 DexGraspVLA，这些物体涵盖了广泛的类别。(b) t-SNE 投影图，展示了所有未见过物体的多样性。每个点代表一个物体，其中颜色表示形状（例如，瓶子、圆柱体、球体），标记类型表示表面粗糙度（光滑、中等、粗糙），点的大小反映质量。该图是从一个高维属性空间（包括长度、宽度、高度、质量、粗糙度和形状）中得出的，突出了这些物体所代表的尺寸、重量、几何形状和纹理的广泛覆盖范围。

3. DexGraspVLA 高级规划器在不同场景下的边界框预测准确度如何？（第 5.4 节）
4. DexGraspVLA 在不同环境下是否表现出一致的内部模型行为？（第 5.5 节）

5.1. 实验设置

硬件平台。如图 3 所示，我们用于灵巧抓取的机器人是一条 7 自由度的 Real-Man RM75-6F 机械臂，搭配 6 自由度的 PsiBot G0-R 手。机械臂腕部安装了一台 RealSense D405C 摄像头，提供第一人称视角，而机器人头部的 RealSense D435 摄像头则提供第三人称视角。待抓取的物体放置在机器人前方的桌子上。控制

	看不见的物体 (360)	未见背景 (6×10^3)	未见闪电 (3×10^3)	总计 (1287)
我们的@1	91.1%	90.5%	90.9%	90.8%
我们的@2	95.3%	94.2%	95.1%	94.7%
我们的@3	96.7%	96.7%	97.4%	96.9%

表 1 | DexGraspVLA 在不同未知条件下的性能表现。第一行表明，DexGraspVLA 在数千种未知的物体、背景和光照组合中始终保持着 90% 以上的成功率，这突显了其对环境变化的强大适应能力和出色的泛化能力。第二行和第三行显示，如果给予更多机会，其成功率甚至有可能达到更高水平。

该机器人的频率为 20 赫兹。

基准方法。据我们所知，目前尚无可直接作为对比基准的工作。大多数灵巧抓取方法无法处理杂乱场景的语言输入，而现有的接受语言输入的视觉语言融合框架又与灵巧手不兼容。因此，我们比较了以下方法：（1）DexGraspVLA(我们的方法):DexGraspVLA 的完整实现。（2）DexGraspVLA (DINOv2-train):与我们的方法设计相同,只是两个 DINOv2 模型是可训练的，而非冻结的。

（3）DexGraspVLA(ViT-small)：与我们的方法设计相同，只是将两个 DINOv2 模型替换为两个小型可训练的预训练 ViT（来自 Steiner 等人的 R26-S-32 ResNet-ViT 混合模型 [80]）。从经验来看，DexGraspVLA (ViT-small) 代表了扩散策略 [78] 的增强版本。这些方法的实现细节在附录 A 中提供。在初步实验中，我们发现失败可能源于策略推理中的随机性，通过额外尝试可以克服。因此，在第 5.2 节中，我们将 DexGraspVLA (Ours@ K) 与 K ranging 分别进行 1 到 3 次尝试的版本进行比较。这些方法与我们的方法相同，只是在每次测试中分别允许 K attempts 1 到 3 次尝试。Ours@1 与 Ours 相当。请注意，在单次尝试中，策略在初始失败后执行的重新抓取操作是允许的，并且不计为单独的尝试。在第 5.4 节中，我们报告了 DexGraspVLA（规划器）的边界框预测性能，这是 DexGraspVLA 中高级规划器的完整实现。

5.2. 大规模泛化评估

任务。我们精心挑选了 360 件此前从未出现过的物品、6 种此前未见过的背景以及 3 种此前未出现过的光照条件。这些物品经过了仔细挑选，以确保涵盖各种不同的尺寸、重量、几何形状和纹理。

这些材料和类别丰富多样，同时也能被我们灵巧的手抓取。这种多样性在图 4 中有所展示。背景和光照条件也被选择得大不相同。基于此设置，我们在杂乱场景中设计了三种抓取任务，每个杂乱场景大约包含六个物体：（1）未见过的物体：从白色桌子上的随机场景中抓取一个未见过的物体，在白色灯光下进行。360 个未见过的物体中的每一个都被抓取一次，总计 360 次测试。（2）未见过的背景：我们首先随机选择 103 个未见过的物体作为物体子集 S 。对于每个背景，我们在白色灯光下随机排列包含 S 中物体的 103 个杂乱场景。每个物体被抓取一次，总共进行 618 次测试。（3）未见过的光照：对于每种未见过的光照，我们在白色桌子上构建包含 S 中物体的 103 个杂乱场景。每个物体被抓取一次，总计 309 次测试。详情见附录 B。

度量标准。如果抓取动作能将物体稳定地举离桌面 10 厘米并保持 20 秒，我们就认为此次抓取尝试成功。我们将成功率作为评估指标，其定义为成功测试次数除以总测试次数。我们还报告了综合性能，即基于各部分成功比例的加权总和。

结果。我们在表 1 中展示了定量结果。从第一行（“Ours@1”）来看，DexGraspVLA 在 360 个未见过的物体上实现了 91.1% 的单次尝试成功率，在 6 个未见过的背景上实现了 90.5%，在 3 种未见过的光照条件下实现了 90.9%，综合成功率达到了 90.8%。这些结果表明，DexGraspVLA 能够准确地控制灵巧手从杂乱环境中抓取指定物体，同时对环境变化具有很强的鲁棒性。值得注意的是，尽管评估环境是全新的，任务也是前所未有的，但 DexGraspVLA 无需任何特定领域的微调就能持续获得高成功率，这突显了其强大的泛化能力。这表明我们的框架在很大程度上缓解了模仿学习中长期存在的挑战，即过度拟合于单一领域并依赖微调以获得令人满意的性能，对于广泛的应用具有潜在意义。我们在 5.5 节进一步分析了这种泛化能力的来源。

从定性角度来看，DexGraspVLA 学会灵活调整机械臂和机械手，以适应不同物体的形状、大小和位置。尽管物理干扰或次优动作偶尔会导致抓取失败，但我们的策略具有闭环特性，能够根据更新后的观察结果重新抓取，从而增强了鲁棒性。该方法还能容忍人为造成的干扰，因为机器人可以




图 5 | 在“零样本”环境中，DexGraspVLA 在已见和未见物体的抓取实验中均显著优于其他设计。这证实了在领域不变特征上应用模仿学习的有效性。

追踪并跟随重新定位的物体，直至成功抓取。

从第二行和第三行（“我们@2”和“我们@3”）可以看出，虽然单次尝试可能会出现随机性和偶然失败，但多次尝试通常会取得成功，三次尝试的总体成功率可提升至 96.9%。这表明我们的方法有能力达到更高的成功率。最后，我们的模型平均抓取一个物体大约需要 6 秒，这与人类的抓取时间接近，确保了在实际场景中的实用性。

总的来说，我们的大规模评估证实，DexGraspVLA 能够稳健地应对各种未见过的场景，这是迈向通用灵巧抓取的重要一步，并有望在更广泛的现实世界中得到应用。

5.3. 与未冻结视觉编码器的基线的比较

任务。为了系统地将 DexGraspVLA 与不使用冻结视觉编码器且直接从原始视觉输入中学习的基线方法进行比较，我们使用训练数据集中 13 个已见过的物体和 8 个未见过的物体进行了单物体抓取实验。我们在桌面上选择了五个位置，这些位置既涵盖了操作工作空间，又在机器人可触及范围内以及头部相机的视野内。每个物体在这五个点各放置一次，每个点让策略抓取两次。请注意，同一物体在同一点的两次抓取被视为两次独立的测试，而非同一测试的重复尝试。这种方法从定量上考虑了实验中的随机性。总共涉及 210 次测试。这些实验的环境条件为白色桌面和白色灯光。

	无干扰	背景干扰	灯光干扰	聚合的
规划师	96.7%	100.0%	100.0%	99.3%

表 2 | DexGraspVLA 规划器在不同环境条件下对杂乱场景中的边界框预测均能稳健地实现近乎完美的准确率。

度量。我们以与 5.2 节相同的方式报告每种方法的成功率。

结果。图 5 表明，DexGraspVLA（我们的方法）在已见和未见物体的抓取实验中均达到了超过 98% 的成功率，显著优于 DexGraspVLA（DINOv2 训练）和 DexGraspVLA（ViT-small）。我们的方法在“零样本”测试环境中的综合性能近乎完美，这表明 DexGraspVLA（我们的方法）不受视觉输入领域偏移的影响。我们还注意到，对未见物体的抓取性能甚至略优于对已见物体的抓取性能，这再次证实我们的模型学会了完成抓取任务，而非在训练集中对已见数据过拟合。相比之下，其他设计在新环境中无法正常工作，因为它们直接将原始输入映射到动作，而感知变化很容易使它们超出分布范围。

5.4. 规划器的边界框预测精度

任务。规划器的边界框预测精度对于抓取的成功至关重要，因为它决定了控制器的目标。为了评估这种精度，我们设计了三种不同环境干扰的任务类型：（1）*无干扰*（1 种场景）：杂乱的场景被布置在白色桌子的白色灯光下；（2）*背景干扰*（2 种场景）：杂乱的场景被放置在白色灯光下的校准板或色彩鲜艳的桌布上；（3）*光照干扰*（2 种场景）：场景被设置在黑暗的房间内，分别由台灯或迪斯科灯照明。对于每种场景，我们随机布置五个杂乱的场景，每个场景包含六个随机选择的物体，然后记录头戴式相机的图像。对于每个物体，我们提供描述其外观和位置的文本提示，并检查规划器的边界框预测是否准确地标记了目标。总体而言，*无干扰*任务有 30 次测试，*背景干扰*和*光照干扰*任务各有 60 次测试，总计 150 次测试。

度量标准。我们将一个边界框定义为准确的，如果它能紧密地包围目标对象。然后，准确性就是




图 6 | DexGraspVLA 对环境变化具有鲁棒性。第一行展示了在四种不同环境中同一堆杂乱物体的裁剪后的原始头部图像：白色桌子、校准板、桌布以及在迪斯科灯光下的桌布。第二行表明 DINOv2 特征在不同环境中保持一致。第三行是 Cutie 准确跟踪的目标物体的掩码。第四行表明 DiT 对头部图像特征的平均注意力图在感知差异下也保持一致。第五行证实 DexGraspVLA 正在关注正确的物体。完整图像见附录 B。

以所有测试对象中准确边界框的比例来衡量。

结果。准确率见表 2。对于 150 个提示，规划器仅对一个边界框标注错误，在其余 149 次测试中均成功，总体准确率超过 99%。这证明了我们的规划器能够可靠地对用户提示进行视觉定位，并且能够在不同程度的背景和光照复杂度下为控制器标记正确的边界框。

5.5. 内部模型行为分析

为了进一步验证我们的设计，我们通过实证证明了内部模型的行为在视觉变化中保持一致，并在图 6 中展示了结果。由于篇幅限制，我们仅展示了每张图像中包含桌面工作区的相关部分。完整的未裁剪图像见附录 B。具体而言，我们设计了四种截然不同的环境条件：白色桌子、校准板、彩色桌布以及带有迪斯科灯光的彩色桌布。在每个环境中，我们都构建了相同的杂乱场景，其中包含九个物体，并让 DexGraspVLA “抓取中间的蓝色酸奶”。尽管图 6 第一行中的头部图像看起来差异显著，但 DINOv2 特征在

第二行看起来相当一致。这些特征通过将主成分映射到 RGB 通道来可视化，正如 Oquab 等人在 [20] 中所做的那样。在不同环境中，物体属性得到了稳健的保持和匹配，这从根本上使得在单一数据域上训练的 Dex-GraspVLA 能够泛化。第三行显示，Cutie 准确地跟踪了物体，为控制器提供了正确的指导。基于域不变掩码和 DINOv2 特征，DiT 动作头现在预测后续动作。在第四行中，我们对 DiT 到头部图像的所有交叉注意力进行平均和归一化。我们发现所有注意力图都表现出相同的聚焦于目标物体而非受环境干扰的行为。第五行将注意力图叠加在原始图像上，以确认合理的注意力模式。所有可视化细节均在附录 B 中提供。因此，我们证实 DexGraspVLA 确实将感知上多样的原始输入转换为不变表示，并在此基础上有效地应用模仿学习来建模数据分布，从而解释了其优越的泛化性能。不出所料，它在所有四种环境中都成功地抓取了酸奶。

6. 局限性

尽管 DexGraspVLA 在一系列未见过的场景中取得了很高的成功率，但仍存在一些局限性。首先，由于时间限制，我们的训练数据集并未涵盖非常小的物体或极度杂乱的环境；在这些更具挑战性的案例中的表现，通过专门的数据收集工作有望得到提升。此外，我们尚未探索用于后续物体使用的功能性抓取，这是未来工作的一个有前景的方向。

7. 结论

本文介绍了 DexGraspVLA，这是首个朝着通用灵巧抓取迈进的分层视觉语言动作框架。它利用预训练的视觉语言模型作为高级规划器来规划抓取过程，并采用基于扩散的策略作为低级控制器来执行抓取的闭环动作预测。在此范式下，DexGraspVLA 利用基础模型的世界知识来理解各种原始输入，并将其转换为领域不变的表示。然后应用模仿学习来建模从表示到动作分布的映射，由于领域偏移的减轻，这种方法非常有效。我们的大规模评估表明，在“零样本”测试环境中，它在数千个未见过的杂乱场景中实现了超过 90% 的

成功率，展示了强大的泛化能力。对其内部模型行为的实证分析进一步验证了其底层框架设计。总体而言，DexGraspVLA 展示了利用基础模型增强灵巧抓取泛化的潜力。我们计划在未来的工作中进一步优化其性能并拓展其应用。

致谢

我们衷心感谢徐一杰在实验方面给予的大力协助，感谢李宇、陈悦和王千旭提出的富有见地的讨论，感谢朱杰对基础模型能力的探索，感谢马成东、于子杰、冯明晓和赵光宇的慷慨帮助。此外，我们非常感谢 PsiBot 的同事们在硬件、工程和采购方面给予的大力支持。

参考文献

- [1] Tao Chen, Megha Tippur, Siyang Wu, Vikash Kumar, Edward Adelson, and Pulkit Agrawal. Visual dexterity: In-hand dexterous manipulation from depth. In *Icml workshop on new frontiers in learning, control, and dynamical systems*, 2023.
- [2] Haozhi Qi, Brent Yi, Sudharshan Suresh, Mike Lambeta, Yi Ma, Roberto Calandra, and Jitendra Malik. General in-hand object rotation with vision and touch. In *Conference on Robot Learning*, pages 2549–2564. PMLR, 2023.
- [3] Binghao Huang, Yuanpei Chen, Tianyu Wang, Yuzhe Qin, Yaodong Yang, Nikolay Atanasov, and Xiaolong Wang. Dynamic handover: Throw and catch with bimanual hands. In *7th Annual Conference on Robot Learning*, 2023.
- [4] Toru Lin, Zhao-Heng Yin, Haozhi Qi, Pieter Abbeel, and Jitendra Malik. Twisting lids off with two hands. *arXiv preprint arXiv:2403.02338*, 2024.
- [5] Yuanpei Chen, Tianhao Wu, Shengjie Wang, Xidong Feng, Jiechuan Jiang, Zongqing Lu, Stephen McAleer, Hao Dong, Song-Chun Zhu, and Yaodong Yang. Towards human-level bimanual dexterous manipulation with reinforcement learning. *Advances in Neural Information Processing Systems*, 35:5150–5163, 2022.
- [6] Kelvin Xu, Zheyuan Hu, Ria Doshi, Aaron Rovinsky, Vikash Kumar, Abhishek Gupta, and Sergey Levine. Dexterous manipulation from images:

- Autonomous real-world rl via substep guidance. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 5938–5945. IEEE, 2023.
- [7] Yuanpei Chen, Chen Wang, Li Fei-Fei, and C Karen Liu. Sequential dexterity: Chaining dexterous policies for long-horizon manipulation. In *Conference on Robot Learning*, pages 3809–3829, 2023.
- [8] Abhishek Gupta, Justin Yu, Tony Z Zhao, Vikash Kumar, Aaron Rovinsky, Kelvin Xu, Thomas Devlin, and Sergey Levine. Reset-free reinforcement learning via multi-task learning: Learning dexterous manipulation behaviors without human intervention. In *2021 IEEE International Conference on Robotics and Automation (ICRA)*, pages 6664–6671. IEEE, 2021.
- [9] Kevin Zakka, Laura Smith, Nimrod Gileadi, Taylor Howell, Xue Bin Peng, Sumeet Singh, Yuval Tassa, Pete Florence, Andy Zeng, and Pieter Abbeel. Robopianist: A benchmark for high-dimensional robot control. *arXiv preprint arXiv:2304.04150*, 2023.
- [10] Sirui Chen, Jeannette Bohg, and C Karen Liu. Springgrasp: An optimization pipeline for robust and compliant dexterous pre-grasp synthesis. *arXiv preprint arXiv:2404.13532*, 2024.
- [11] Dylan Turpin, Tao Zhong, Shutong Zhang, Guanglei Zhu, Eric Heiden, Miles Macklin, Stavros Tsogkas, Sven Dickinson, and Animesh Garg. Fast-grasp²: Dexterous multi-finger grasp generation through differentiable simulation. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 8082–8089. IEEE, 2023.
- [12] Dylan Turpin, Liquan Wang, Eric Heiden, Yun-Chun Chen, Miles Macklin, Stavros Tsogkas, Sven Dickinson, and Animesh Garg. Grasp²: Differentiable contact-rich grasp synthesis for multi-fingered hands. In *European Conference on Computer Vision*, pages 201–221. Springer, 2022.
- [13] Ilge Akkaya, Marcin Andrychowicz, Maciek Chociej, Mateusz Litwin, Bob McGrew, Arthur Petron, Alex Paino, Matthias Plappert, Glenn Powell, Raphael Ribas, et al. Solving rubik’s cube with a robot hand. *arXiv preprint arXiv:1910.07113*, 2019.
- [14] Max Yang, Chenghua Lu, Alex Church, Yijiong Lin, Chris Ford, Haoran Li, Efi Psomopoulou, David AW Barton, and Nathan F Lepora. Any-rotate: Gravity-invariant in-hand object rotation with sim-to-real touch. *arXiv preprint arXiv:2405.07391*, 2024.
- [15] Johannes Pitz, Lennart Röstel, Leon Sievers, and Berthold Bäuml. Dexterous tactile in-hand manipulation using a modular reinforcement learning architecture. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 1852–1858. IEEE, 2023.
- [16] Ankur Handa, Arthur Allshire, Viktor Makoviychuk, Aleksei Petrenko, Ritvik Singh, Jingzhou Liu, Denys Makoviichuk, Karl Van Wyk, Alexander Zhurkevich, Balakumar Sundaralingam, et al. Dextreme: Transfer of agile in-hand manipulation from simulation to reality. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 5977–5984, 2023.
- [17] Chen Wang, Haochen Shi, Weizhuo Wang, Ruohan Zhang, Li Fei-Fei, and C Karen Liu. Dexcap: Scalable and portable mocap data collection system for dexterous manipulation. *arXiv preprint arXiv:2403.07788*, 2024.
- [18] Zoey Qiuyu Chen, Karl Van Wyk, Yu-Wei Chao, Wei Yang, Arsalan Mousavian, Abhishek Gupta, and Dieter Fox. Dextranet: Real world multi-fingered dexterous grasping with minimal human demonstrations. *arXiv preprint arXiv:2209.14284*, 2022.
- [19] Aravind Rajeswaran, Vikash Kumar, Abhishek Gupta, Giulia Vezzani, John Schulman, Emanuel Todorov, and Sergey Levine. Learning complex dexterous manipulation with deep reinforcement learning and demonstrations. In *Robotics: Science and Systems*, 2017.
- [20] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, et al. Dinov2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*, 2023.
- [21] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pages 8748–8763. PMLR, 2021.
- [22] Aaron Hurst, Adam Lerer, Adam P Goucher, Adam Perelman, Aditya Ramesh, Aidan Clark,

- AJ Ostrow, Akila Welihinda, Alan Hayes, Alec Radford, et al. Gpt-4o system card. *arXiv preprint arXiv:2410.21276*, 2024.
- [23] Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao, Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer Whitehead, Alexander C Berg, Wan-Yen Lo, et al. Segment anything. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 4015–4026, 2023.
- [24] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, et al. Sam 2: Segment anything in images and videos. *arXiv preprint arXiv:2408.00714*, 2024.
- [25] Wenlong Huang, Chen Wang, Ruohan Zhang, Yunzhu Li, Jiajun Wu, and Li Fei-Fei. Voxposer: Composable 3d value maps for robotic manipulation with language models. In *Conference on Robot Learning*, pages 540–562, 2023.
- [26] Wenlong Huang, Chen Wang, Yunzhu Li, Ruohan Zhang, and Li Fei-Fei. Rekep: Spatio-temporal reasoning of relational keypoint constraints for robotic manipulation. In *8th Annual Conference on Robot Learning*, 2024.
- [27] Moo Jin Kim, Karl Pertsch, Siddharth Karamcheti, Ted Xiao, Ashwin Balakrishna, Suraj Nair, Rafael Rafailov, Ethan Foster, Grace Lam, Pan-nag Sanketi, et al. Openvla: An open-source vision-language-action model. *arXiv preprint arXiv:2406.09246*, 2024.
- [28] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Nicolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A Vision-Language-Action Flow Model for General Robot Control. *arXiv preprint arXiv:2410.24164*, 2024.
- [29] Alexander Khazatsky, Karl Pertsch, Suraj Nair, Ashwin Balakrishna, Sudeep Dasari, Siddharth Karamcheti, Soroush Nasiriany, Mohan Kumar Srirama, Lawrence Yunliang Chen, Kirsty Ellis, et al. Droid: A large-scale in-the-wild robot manipulation dataset. In *Robotics: Science and Systems*, 2024.
- [30] Abby O’Neill, Abdul Rehman, Abhinav Gupta, Abhiram Maddukuri, Abhishek Gupta, Abhishek Padalkar, Abraham Lee, Acorn Pooley, Agrim Gupta, Ajay Mandlekar, et al. Open x embodiment: Robotic learning datasets and rt-x models. *arXiv preprint arXiv:2310.08864*, 2023.
- [31] Jens Lundell, Francesco Verdoja, and Ville Kyrki. Ddgc: Generative deep dexterous grasping in clutter. *IEEE Robotics and Automation Letters*, 6(4):6899–6906, 2021.
- [32] Andrew T Miller and Peter K Allen. Graspit! a versatile simulator for robotic grasping. *IEEE Robotics & Automation Magazine*, 11(4):110–122, 2004.
- [33] Tengyu Liu, Zeyu Liu, Ziyuan Jiao, Yixin Zhu, and Song-Chun Zhu. Synthesizing diverse and physically stable grasps with arbitrary hand structures using differentiable force closure estimator. *IEEE Robotics and Automation Letters*, 7(1):470–477, 2021.
- [34] Puhao Li, Tengyu Liu, Yuyang Li, Yiran Geng, Yixin Zhu, Yaodong Yang, and Siyuan Huang. Gendexgrasp: Generalizable dexterous grasping. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 8068–8074. IEEE, 2023.
- [35] Ruicheng Wang, Jialiang Zhang, Jiayi Chen, Yinzhen Xu, Puhao Li, Tengyu Liu, and He Wang. Dexgraspnet: A large-scale robotic dexterous grasp dataset for general objects based on simulation. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 11359–11366. IEEE, 2023.
- [36] Jialiang Zhang, Haoran Liu, Danshi Li, XinQiang Yu, Haoran Geng, Yufei Ding, Jiayi Chen, and He Wang. Dexgraspnet 2.0: Learning generative dexterous grasping in large-scale synthetic cluttered scenes. In *8th Annual Conference on Robot Learning*, 2024.
- [37] Yiming Li, Wei Wei, Daheng Li, Peng Wang, Wanyi Li, and Jun Zhong. Hgc-net: Deep anthropomorphic hand grasping in clutter. In *2022 International Conference on Robotics and Automation (ICRA)*, pages 714–720. IEEE, 2022.
- [38] Min Liu, Zherong Pan, Kai Xu, Kanishka Ganguly, and Dinesh Manocha. Deep differentiable grasp planner for high-dof grippers. In *Robotics: Science and Systems*, 2020.
- [39] Jiaxin Lu, Hao Kang, Haoxiang Li, Bo Liu, Yiding Yang, Qixing Huang, and Gang Hua. Ugg: Unified generative grasping. In *European Conference on Computer Vision*, pages 414–433. Springer, 2025.
- [40] Tao Chen, Jie Xu, and Pulkit Agrawal. A system for general in-hand object re-orientation. *Conference on Robot Learning*, 2021.

- [41] Zhao-Heng Yin, Binghao Huang, Yuzhe Qin, Qifeng Chen, and Xiaolong Wang. Rotating without seeing: Towards in-hand dexterity through touch. In *Robotics: Science and Systems*, 2023.
- [42] Haozhi Qi, Ashish Kumar, Roberto Calandra, Yi Ma, and Jitendra Malik. In-hand object rotation via rapid motor adaptation. In *Conference on Robot Learning*, pages 1722–1732. PMLR, 2023.
- [43] Sudeep Dasari, Abhinav Gupta, and Vikash Kumar. Learning dexterous manipulation from exemplar object trajectories and pre-grasps. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 3889–3896. IEEE, 2023.
- [44] Gagan Khandate, Siqi Shang, Eric T Chang, Tristan Luca Saidi, Yang Liu, Seth Matthew Dennis, Johnson Adams, and Matei Ciocarlie. Sampling-based exploration for reinforcement learning of dexterous manipulation. In *Robotics: Science and Systems*, 2023.
- [45] Yuanpei Chen, Chen Wang, Yaodong Yang, and C Karen Liu. Object-centric dexterous manipulation from human motion data. In *8th Annual Conference on Robot Learning*, 2024.
- [46] Weikang Wan, Haoran Geng, Yun Liu, Zikang Shan, Yaodong Yang, Li Yi, and He Wang. Unidexgrasp++: Improving dexterous grasping policy learning via geometry-aware curriculum and iterative generalist-specialist learning. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 3891–3902, 2023.
- [47] Hui Zhang, Sammy Christen, Zicong Fan, Otmar Hilliges, and Jie Song. Grasppl: Generating grasping motions for diverse objects at scale. In *European Conference on Computer Vision*, pages 386–403. Springer, 2024.
- [48] Zhecheng Yuan, Tianming Wei, Shuiqi Cheng, Gu Zhang, Yuanpei Chen, and Huazhe Xu. Learning to manipulate anywhere: A visual generalizable framework for reinforcement learning. *CoRR*, abs/2407.15815, 2024. doi: 10.48550/ARXIV.2407.15815. URL <https://doi.org/10.48550/arXiv.2407.15815>.
- [49] Priyanka Mandikal and Kristen Grauman. Dexvip: Learning dexterous grasping with human hand pose priors from video. In *Conference on Robot Learning*, pages 651–661. PMLR, 2022.
- [50] Priyanka Mandikal and Kristen Grauman. Learning dexterous grasping with object-centric visual affordances. In *2021 IEEE international conference on robotics and automation (ICRA)*, pages 6169–6176. IEEE, 2021.
- [51] Tyler Ga Wei Lum, Martin Matak, Viktor Makovychuk, Ankur Handa, Arthur Allshire, Tucker Hermans, Nathan D Ratliff, and Karl Van Wyk. Dextrah-g: Pixels-to-action dexterous arm-hand grasping with geometric fabrics. In *8th Annual Conference on Robot Learning*, 2024.
- [52] Ritvik Singh, Arthur Allshire, Ankur Handa, Nathan Ratliff, and Karl Van Wyk. Dextrah-rgb: Visuomotor policies to grasp anything with dexterous hands. *arXiv preprint arXiv:2412.01791*, 2024.
- [53] Zoey Qiuyu Chen, Karl Van Wyk, Yu-Wei Chao, Wei Yang, Arsalan Mousavian, Abhishek Gupta, and Dieter Fox. Learning robust real-world dexterous grasping policies via implicit shape augmentation. In *Conference on Robot Learning*, pages 1222–1232, 2022.
- [54] Ilija Radosavovic, Xiaolong Wang, Lerrel Pinto, and Jitendra Malik. State-only imitation learning for dexterous manipulation. In *2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 7865–7871. IEEE, 2021.
- [55] Sridhar Pandian Arunachalam, Irmak Güzey, Soumith Chintala, and Lerrel Pinto. Holo-dex: Teaching dexterity with immersive mixed reality. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 5962–5969. IEEE, 2023.
- [56] Irmak Guzey, Ben Evans, Soumith Chintala, and Lerrel Pinto. Dexterity from touch: Self-supervised pre-training of tactile representations with robotic play. In *7th Annual Conference on Robot Learning*, 2023.
- [57] Ankur Handa, Karl Van Wyk, Wei Yang, Jacky Liang, Yu-Wei Chao, Qian Wan, Stan Birchfield, Nathan Ratliff, and Dieter Fox. Dexpilot: Vision-based teleoperation of dexterous robotic hand-arm system. In *2020 IEEE International Conference on Robotics and Automation (ICRA)*, pages 9164–9170. IEEE, 2020.
- [58] Aravind Sivakumar, Kenneth Shaw, and Deepak Pathak. Robotic telekinesis: Learning a robotic hand imitator by watching humans on youtube. In *Robotics: Science and Systems*, 2022.
- [59] Yuzhe Qin, Wei Yang, Binghao Huang, Karl Van Wyk, Hao Su, Xiaolong Wang, Yu-Wei Chao,

- and Dietor Fox. Anyteleop: A general vision-based dexterous robot arm-hand teleoperation system. *arXiv preprint arXiv:2307.04577*, 2023.
- [60] Yuzhe Qin, Yueh-Hua Wu, Shaowei Liu, Han-wen Jiang, Ruihan Yang, Yang Fu, and Xiaolong Wang. Dexmv: Imitation learning for dexterous manipulation from human videos. In *European Conference on Computer Vision*, pages 570–587. Springer, 2022.
- [61] Zichen Jeff Cui, Yibin Wang, Nur Muham-mad Mahi Shafiullah, and Lerrel Pinto. From play to policy: Conditional behavior generation from uncurated robot data. In *The International Conference on Learning Representations*, 2023.
- [62] Siddhant Haldar, Jyothish Pari, Anant Rai, and Lerrel Pinto. Teach a robot to fish: Versatile imitation from one minute of demonstrations. *arXiv preprint arXiv:2303.01497*, 2023.
- [63] Yuzhe Qin, Hao Su, and Xiaolong Wang. From one hand to multiple hands: Imitation learning for dexterous manipulation from single-camera teleoperation. *IEEE Robotics and Automation Letters*, 7(4):10873–10881, 2022.
- [64] Sridhar Pandian Arunachalam, Sneha Silwal, Ben Evans, and Lerrel Pinto. Dexterous imi-tation made easy: A learning-based framework for efficient dexterous manipulation. In *2023 IEEE International Conference on Robotics and Automation (ICRA)*, pages 5954–5961, 2023.
- [65] Irmak Guzey, Yinlong Dai, Ben Evans, Soumith Chintala, and Lerrel Pinto. See to touch: Learning tactile dexterity through visual incentives. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 13825–13832. IEEE, 2024.
- [66] Toru Lin, Yu Zhang, Qiyang Li, Haozhi Qi, Brent Yi, Sergey Levine, and Jitendra Malik. Learning visuotactile skills with two multifingered hands. *arXiv preprint arXiv:2404.16823*, 2024.
- [67] Qianxu Wang, Haotong Zhang, Congyue Deng, Yang You, Hao Dong, Yixin Zhu, and Leonidas Guibas. Sparsedff: Sparse-view feature distil-lation for one-shot dexterous manipulation. In *The Twelfth International Conference on Learning Representations*, 2023.
- [68] Qianxu Wang, Congyue Deng, Tyler Ga Wei Lum, Yuanpei Chen, Yaodong Yang, Jeannette Bohg, Yixin Zhu, and Leonidas Guibas. Neural atten-tion field: Emerging point relevance in 3d scenes for one-shot dexterous grasping. In *8th Annual Conference on Robot Learning*, 2024.
- [69] Mathilde Caron, Hugo Touvron, Ishan Misra, Hervé Jégou, Julien Mairal, Piotr Bojanowski, and Armand Joulin. Emerging properties in self-supervised vision transformers. In *Proceedings of the IEEE/CVF international conference on com-puter vision*, pages 9650–9660, 2021.
- [70] Qwen Team. Qwen2.5-vl, January 2025. URL <https://qwenlm.github.io/blog/qwen2.5-vl/>.
- [71] Shaofei Cai, Zihao Wang, Kewei Lian, Zhancun Mu, Xiaojian Ma, Anji Liu, and Yitao Liang. Rocket-1: Mastering open-world interaction with visual-temporal context prompting. *arXiv preprint arXiv:2410.17856*, 2024.
- [72] Zihao Wang, Shaofei Cai, Zhancun Mu, Haowei Lin, Ceyao Zhang, Xuejie Liu, Qing Li, Anji Liu, Xiaojian Shawn Ma, and Yitao Liang. Omnijarvis: Unified vision-language-action tokenization en-ables open-world instruction following agents. *Advances in Neural Information Processing Sys-tems*, 37:73278–73308, 2025.
- [73] Anthony Brohan, Noah Brown, Justice Carbajal, Yevgen Chebotar, Xi Chen, Krzysztof Choroman-ski, Tianli Ding, Danny Driess, Avinava Dubey, Chelsea Finn, et al. Rt-2: Vision-language-action models transfer web knowledge to robotic con-trol. *arXiv preprint arXiv:2307.15818*, 2023.
- [74] Chi-Lam Cheang, Guangzeng Chen, Ya Jing, Tao Kong, Hang Li, Yifeng Li, Yuxiao Liu, Hongtao Wu, Jiafeng Xu, Yichu Yang, et al. Gr-2: A gen-erative video-language-action model with web-scale knowledge for robot manipulation. *arXiv preprint arXiv:2410.06158*, 2024.
- [75] Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou. Qwen-vl: A versatile vision-language model for understand-ing, localization, text reading, and beyond. *arXiv preprint arXiv: 2308.12966*, 1(2):3, 2023.
- [76] Ho Kei Cheng, Seoung Wug Oh, Brian Price, Joon-Young Lee, and Alexander Schwing. Putting the object back into video object segmen-tation. In *Proceedings of the IEEE/CVF Confer-ence on Computer Vision and Pattern Recognition*, pages 3151–3161, 2024.
- [77] William Peebles and Saining Xie. Scalable diffu-sion models with transformers. In *Proceedings of the IEEE/CVF International Conference on Com-puter Vision*, pages 4195–4205, 2023.

- [78] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 2023.
- [79] Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*, 2024.
- [80] Andreas Peter Steiner, Alexander Kolesnikov, Xi-aohua Zhai, Ross Wightman, Jakob Uszkoreit, and Lucas Beyer. How to train your vit? data, augmentation, and regularization in vision transformers. *Transactions on Machine Learning Research*, 2022.
- [81] Yiheng Li, Heyang Jiang, Akio Kodaira, Masayoshi Tomizuka, Kurt Keutzer, and Chen-feng Xu. Immiscible diffusion: Accelerating diffusion training with noise assignment. *arXiv preprint arXiv:2406.12303*, 2024.
- [82] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. In *International Conference on Learning Representations*, 2020.

A. 实施细节

在本节中，我们将介绍 DexGraspVLA 的实现细节（附录 A.1）、基线实现（附录 A.2）以及数据集收集（附录 A.3）。

A.1. DexGraspVLA 实现的详细信息

规划器。高级规划器的运行方式如第 4.1 节所述。为了使用 Qwen-VL-Chat 为低级控制器获取边界框，我们首先从头部相机图像中裁剪出与桌面工作区相对应的固定区域。然后将此裁剪区域输入到视觉语言模型（VLM）中，该模型识别出其中目标物体的边界框。最后，将坐标映射回原始图像，以确定控制器使用的边界框。几个标注结果如图 10 所示。

通过利用现成的视觉语言模型（VLM）作为规划器，我们的框架获得了显著的灵活性，能够轻松地将原始的 VLM 替换为更先进的模型以提升性能。我们的观察表明，Qwen2.5-VL-72B-Instruct [70] 在推

理和指令遵循方面优于 Qwen-VL-Chat（我们在实验中使用的模型，见第 5 节），从而提高了长时任务的完成度。此外，使用 72B 模型时，规划器在不进行图像裁剪的情况下就能实现近乎完美的边界框预测精度。因此，我们在此提供了基于 Qwen2.5-VL-72B-Instruct 的 DexGraspVLA 规划器的提示。

这些提示主要指导视觉语言模型（VLM）作为 DexGraspVLA 规划器运行，包括理解用户提示、提出当前抓取指令的对象、标记目标对象的边界框、检查抓取是否成功、评估当前指令是否完成以及判断整个用户提示是否已完全实现。具体来说，当用户提示 p 提供时，规划器会根据以下提示中是否 $p_{\text{explicitly}}$ 指定了目标对象来对其类型进行分类。

分析以下用户提示：<用户提示>

用户提示类型：

- 类型 I（返回 True）：用户提示包含任何具体描述 示例：

基于颜色的：“绿色物体”

基于位置的：“右边的物体” 基于属性的：“所有的杯子”

组合：“左边的红色杯子” - 类型 II（返回 False）：没有任何对象描述的抽象提示

示例：“清理餐桌”，“收拾干净”，“把所有东西都拿走” 请判断：

- 这是一个 I 型提示吗？（对/错） - 请给出您的理由 回答格式：

判断题：你的推理 示例： -
“拿起绿色的杯子” -> 真：
包含具体对象（杯子）和
属性（绿色） - “清理桌子” -> 假：未提及具体对象的特征

如果 p_{is} 被归类为“类型 I”，即明确指出了要抓取的物体，那么规划器会使用以下提示和前置摄像头图像生成一个有序的抓取指令列表。

对于用户提示: <用户提示> 过程:

1. 结合用户提示和图片进行分析:

将用户提示描述与图像中的可见物体进行匹配

- 如果描述 (例如 “绿色物体”) 与多个物体相符, 则包含所有匹配的物体- 核实所提及的每个物体在图像中确实存在

2. 根据机械臂的位置 (屏幕右边缘) 和桌面布局

3. 确定最高效的抓取顺序

4. 生成一个需抓取对象的重新排序列表 要求:

- 仅包含原始用户提示中提到的物体 - 保留每个物体的位置信息 - 以列表形式返回, 按抓取顺序排列 预期输出格式: [“位置 1 的物体”, “位置 2 的物体”, ...]

或者, 如果 p_{is} 被归类为 “II 型”, 表明当用户意图抓取桌面上的所有物体时, 规划器会根据桌面上剩余的物体, 利用以下提示和头戴式摄像头图像, 选择最优的目标物体作为当前指令。

分析当前桌面布局, 并根据以下因素选择最合适的物体进行抓取:

把握策略:

1. 机械臂位于最右侧 (在画面之外)。

2. 把握优先顺序:

- 优先处理右侧的物品, 以免在后续操作中碰倒其他物品- 然后考虑中间的物品- 最后考虑左侧的物品

3. 可达性分析: - 物体之间的相对位置 - 潜在障碍物 - 抓取路径是否会与其他物体发生干涉

请以以下 JSON 格式提供您的回复:

对于每个抓取指令 L , 规划器都会标记使用以下提示和头戴式摄像头拍摄的图像来确定目标物体的边界框。

分析图像并找出与描述<目标对象>最匹配的物体。

物品分析说明:

1. 选择一个最符合描述的物品

2. 对于所选对象, 请提供: - 简洁的标签, 对象名称 (最多 3-4 个词) - 详细描述 (位置、颜色、形状、背景) - 精确的边界框坐标

所需的 JSON 格式及示例:

```
{
  "bbox_2d": [x1, y1, x2, y2],
  "label": "green cup", # Keep
    this very brief (3-4 words)
  "description": "a cylindrical
    green ceramic cup located
    on the right side of the
    wooden table, next to the
    laptop" # Detailed
    description
}
```

关键要求：- 必须返回 EXACTLY ONE 个对象

- “标签”：必须简短（3-4 个词），便于快速参考- “描述”：必须详细，并包含空间背景信息- 使用单个 JSON 对象格式，而非数组- 确保边界框坐标在图像边界内

在控制器执行期间，规划器会使用以下提示和头部摄像头图像来验证物体是否已被成功抓取。

分析图像并判断机械臂是否成功抓取了物体：

1. 观察机械手与物体之间的空间关系
2. 输出格式：解释你的推理，然后用一个布尔值结束（True=掌握，False=未掌握）

当抓取尝试结束时，机器人会重置到初始状态，然后规划器会使用以下提示和头部摄像头图像来检查当前指令是否已完成。

请检查桌面是否存在 <目标对象>。如果不存在，请输出 True；否则，请输出 False。

对于“类型 I”的用户提示 P，如果所有指定的物体都已成功抓取，规划器就认为该提示已得到满足。对于“类型 II”的用户提示 P，规划器在每次抓取尝试后，都会使用以下提示和头部摄像头图像来检查该提示是否已完全完成。

请分析图片中的表格：

要求：

- 仅检测具有明显高度/厚度的实体物体（三维物体）- 不予考虑：
- 若桌面无任何三维物体：返回“True”- 若桌面有三维物体：返回“False”，并附上其名称* 平面物品（纸张、桌布、垫子）* 光线投射 * 阴影 * 表面图案或纹理

示例回答：真（对于空桌子）假：杯子、瓶子、盘子（对于有物品的桌子）

控制器。所有原始图像均由头部和手腕相机以 $640 \times 480 \times 3$ 的分辨率生成。相应地，掩码的分辨率为 $640 \times 480 \times 1$ 。通过初步模型选择，我们决定使用 DINOv2 ViT-B/14 作为头部相机图像的特征提取器^h，使用 DINOv2 ViT-L/14 作为手腕相机图像的特征提取器^w。在将图像输入 DINOv2 之前，我们将其调整为 $518 \times 518 \times 3$ 的大小。在训练过程中，我们通过颜色抖动应用域随机化。最后，对图像进行归一化处理并输入到 DINOv2 模型中。这将得到特征 $\mathbf{z}_T^h \in \mathbb{R}^{1369 \times 768}$ 和 $\mathbf{z}_T^w \in \mathbb{R}^{1369 \times 1024}$ 。通过

处理掩码 $\mathbf{m}_T$ with 一个随机初始化的视觉变换器（ViT），我们提取其特征 $\mathbf{z}_T^m \in \mathbb{R}^{1369 \times 768}$ 。按补丁方式从 $\mathbf{z}_T^h$ and 到 $\mathbf{z}_T^m$ leads 的串联，然后投影到 $\mathbb{R}^{1369 \times 1536}$ 。接着我们回溯 $\mathbf{z}_T^h, \mathbf{z}_T^w$

到 $\mathbb{R}^{1024}$ 相同的特征空间，分别使用独立的多层感知机（MLP），得到 $\mathbf{z}_T^h \in \mathbb{R}^{1369 \times 1024}$ 、 $\mathbf{z}_T^w \in \mathbb{R}^{1369 \times 1024}$ 、 $\mathbf{z}_T^m \in \mathbb{R}^{1 \times 1024}$ ，然后将它们连接起来形成完整的观测特征序列 $\mathbf{z}_{obs} = (\mathbf{z}_T^h, \mathbf{z}_T^w, \mathbf{z}_T^m) \in \mathbb{R}^{2739 \times 1024}$ 。

对于动作建模，我们将动作块的时间范围定义为 $H=64$ 。在训练过程中向动作添加噪声时，我们采用不混淆扩散 [81] 来改善数据噪声映射。添加噪声后的动作块从 $\mathbf{A}_T \in \mathbb{R}^{64 \times 13}$ 变为 $\mathbf{A}_T^A \in \mathbb{R}^{64 \times 13}$ 。

DiT 的实现基于原始的 DiT 论文 [77]、扩散策略 [78] 以及 RDT [79]。首先将扩散时间步长嵌入到与 $\mathbf{z}_{obs}^T$ 相同的隐藏空间中，得到 $\mathbf{z}_{d,T} \in \mathbb{R}^{1 \times 1024}$ ，然后将其与 $\mathbf{z}_{obs}^T$ 拼接，形成条件序列 $\mathbf{z}_T = (\mathbf{z}_{obs}, \mathbf{z}_{d,T}) \in \mathbb{R}^{2740 \times 1024}$ 。我们对 $\mathbf{z}_T$ 进行投影

将带噪声的动作块映射到相同的隐藏空间，得到 $\mathbf{z}_T^A \in \mathbb{R}^{64 \times 1024}$ ，然后将其输入到 DiT 中。每个 DiT 层都在动作标记内执行双向注意力操作，与条件序列进行交叉注意力操作，并进行多层感知机投影。最后，将输出投影回动作空间，作为模型对噪声的预测。在训练期间，我们计算噪声预测与真实值之间的均方误差损失，并反向传播梯度以更新所有可训练参数。在推理期间，我们从高斯噪声开始，并使用 DDIM 采样 [82] 迭代去噪。在每一步中，DiT 模型根据条件序列预测噪声，然后我们使用 DDIM 调度器更新动作块，直到获得最终动作。控制器仅执行预测动作块中的前六个动作，然后进行新的预测。

该控制器总共拥有 1.63 亿个可训练参数。为了加快训练速度，我们采用了 bfloat16。

超参数	价值
纪元	84
学习率	0.0001
学习率调度器	余弦
学习率预热步数	2000
权重衰减	0.0001
AdamW 超参数	[0.95, 0.999]
种子	42
每个GPU的批次大小	48
作用视界	64
DiT 层的数量	12
DiT 头的数量	8
注意力丢弃	0.1
噪声调度器	DDIM调度器
训练步数	50
测试版开始	0.0001
结束测试阶段	0.02
测试版时间表	squaredcos_cap_v2
剪辑样本	真的
设置透明度为 1	真的
步数偏移量	0
预测类型	ϵ (希腊字母)
推理步骤数	16

表 3 | DexGraspVLA 的超参数。

我们采用了混合精度训练，以减少内存使用并提高计算效率。此外，我们使用 FusedAdamW 作为优化器，通过优化内存访问和融合内核执行进一步加快训练速度。借助这些技术，我们在配备 8 块 A800 GPU 的服务器上对控制器进行了 84 个周期的训练，整个过程不到一天即可完成。我们实现中所有超参数的详细信息见附录 A.1。

A.2. 基准实施详情

基准 DexGraspVLA (DINOv2 训练) 与附录 A.1 中描述的 DexGraspVLA (我们的方法) 相同，只是两个 DINOv2 模型是可训练的，而非冻结的。基准 DexGraspVLA (ViT-small) 与 DexGraspVLA (我们的方法) 相同，只是将两个 DINOv2 模型替换为两个小型可训练的预训练 ViT (来自 Steiner 等人 [80] 的 R26-S-32 ResNet-ViT 混合模型)。相应地，我们将图像调整为 $224 \times 224 \times 3$ 的尺寸以输入 ViT-small。每张图像被分割成 49 个补丁，特征维度为 384。

A.3. 数据收集详情

我们通过运动觉教学收集演示动作。起初，将机器人设置为教学模式，这样就可以通过手动引导来抓取目标物体。



(a) Our data collection site.



(b) The test environment where all experiments are conducted.

图 7 | 对位于不同房间的数据采集和测试环境的比较。值得注意的是，机器人摄像头所捕捉到的场景差异显著，尤其是腕部摄像头。

操作员随后引导机器人到达目标位置并执行抓取动作。整个过程遵循固定时长 (以 20Hz 的频率记录 75 个关节角度值)。随后，我们重置环境，并使用记录的关节角度作为目标执行 PD 控制。以相同的频率，这些目标关节角度作为动作，同时收集图像和当前关节角度作为状态。与低级控制器采用相同的方法，我们对收集到的数据进行后期处理以生成掩码，从而完成一个演示序列。

B. 实验详情

B.1. “零样本”评估环境

图 7 对比了我们的数据采集地点和测试地点，这两个地点位于不同的房间。我们在数据采集地点 (图 7a) 收集了全部 2094 次人类演示，而第 5 节中的实验则是在测试地点 (图 7b) 进行的。由于这两个地点在布局 and 背景方面存在差异，在评估过程中，头部摄像头和腕部摄像头都会遇到训练数据中没有出现过的场景，尤其是腕部摄像头，它所观察到的场景中没有——

在明显改变的环境中进行操作，捕捉到各种正面和侧面的视角。尽管存在这些环境差异，我们并未从测试场地收集任何数据来微调模型。相反，模型直接部署并进行评估，从而形成了一个真正的“零样本”测试环境。即便在这种条件下，DexGraspVLA 在杂乱场景中的抓取任务中，对数千种未见过的物体、光照和背景组合仍能实现超过 90% 的成功率，这清楚地表明了其强大的泛化能力。

B.2. 对象、灯光和背景的更多细节

我们总共收集了 360 个未见过的物品，从中随机选取了 103 件作为物品子集 S 。在主论文中，*未见过物品* 实验是在全部 360 个物品上进行的，而*未见过光照和未见过背景* 实验仅使用子集 S 中的物品。三种未见过的光照条件包括迪斯科灯光、台灯灯光和暗光。同时，六个未见过的背景包括黑色鼠标垫、粉色毛巾、彩色桌布、黑白鼠标垫、木板和校准板。这些条件在图 8 中有所展示。

B.3. 可视化详情

在本部分，我们将解释如何对图 6 中展示的内部模型行为进行可视化。由于篇幅限制，图 6 仅展示了包含桌面工作区的相关图像部分。完整版本见图 9。第一行是来自头部相机的原始图像，已调整为 $518 \times 518 \times 3$ 的大小。第二行展示了遵循 DINOv2 论文 [20] 中介绍的实践所得出的 DINOv2 ViT-B/14 特征。为了便于可视化，我们在将图像输入 DINOv2 之前，将其高度和宽度均放大了六倍。获取所有四张图像的特征序列后，我们将这些特征组合起来，在所有补丁之间执行主成分分析（PCA），并设置阈值以去除背景区域。然后，我们再次对剩余的前景特征执行 PCA，将前三个主成分映射到 RGB 通道，并对结果进行归一化处理。这便得到了第二行所示的可视化结果。第三行展示了由 Cutie 跟踪的二值掩码 $\mathbf{m}_T \in \mathbb{R}^{518 \times 518 \times 1}$ 。第四行显示了头部图像特征的平均 DiT 注意力图。这是通过将每个扩散步骤、DiT 层、DiT 头和动作标记对每个头部图像块的注意力权重相加计算得出的，并将总和归一化为 1。平均注意力图的

形状为 $37 \times 37 \times 1$ 。最后，我们将注意力图上采样到 $518 \times 518 \times 1$ ，乘以 2 以增加亮度，并将其用于在 HSV 空间中缩放头部图像的值通道，从而得到第五行所示的可视化结果。

C. 附加结果

本节提供了主论文中实验的更多结果。在表 4 中，我们报告了在各种环境条件下进行的大规模泛化评估的详细成功率，这与第 5.2 节中的表 1 相对应。从第一行（“Ours@1”）可以看出，DexGraspVLA 在各种未见过的物体、光照和背景组合下始终保持着较高的成功率。许多观察到的失败案例源于策略推断中的随机性；允许额外的尝试通常可以恢复这些失败的情况。因此，第二行和第三行（“Ours@2”和“Ours@3”）显示了性能的进一步提升，突显了 DexGraspVLA 达到更高成功率的潜力。在图 10 中，我们展示了由 DexGraspVLA 规划器生成的边界框预测示例。尽管环境条件存在很大差异，但规划器始终能在杂乱的场景中确定抓取指令，并提供正确的边界框。值得注意的是，我们可以用诸如“可口可乐”或“牛奶”这样的名称来标注物体，这反映了该系统丰富的常识和世界知识。通过利用其每个基础模型中所蕴含的广泛知识，DexGraspVLA 实现了在各种不同场景下的稳健泛化。

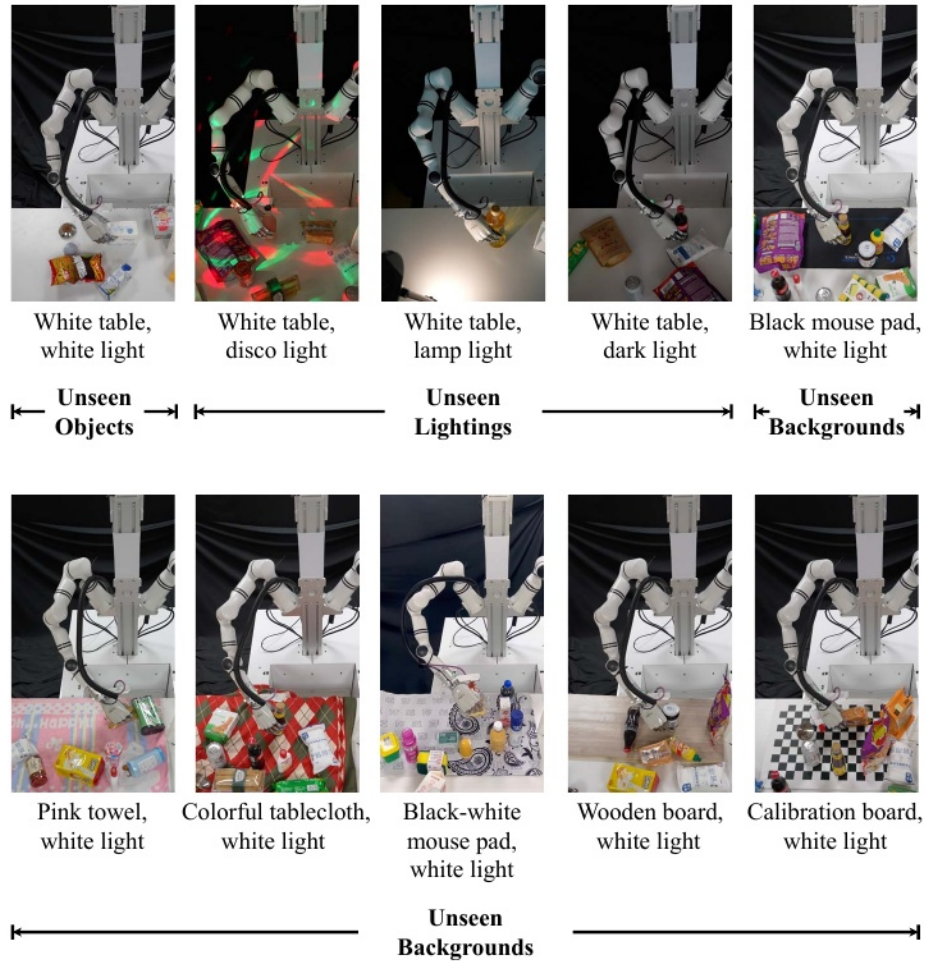


图 8 | 我们在大规模泛化评估中使用的环境条件（第 5.2 节）。

任务	看不见的物体 (360)	未见闪电 (3×10^3)			未见背景 (6×10^3)						总计 (1287)
照明条件	白光	迪斯科灯	灯光	暗光	白光	白光	白光	白光	白光	白光	
背景条件	白桌	白桌	白桌	白桌	黑色鼠标垫	粉色毛巾	彩色桌布	黑白鼠标垫	木板	校准板	
我们的@1	91.1%	92.2%	89.3%	91.2%	94.2%	84.5%	90.3%	92.2%	93.2%	88.3%	90.8%
我们的@2	95.3%	97.0%	95.1%	93.2%	97.1%	90.3%	91.3%	95.1%	98.1%	93.2%	94.7%
我们的@3	96.7%	98.1%	98.1%	96.1%	98.1%	91.3%	94.2%	98.1%	100.0%	98.1%	96.9%

表 4 | DexGraspVLA 在不同未知条件下的详细性能表现，表明我们的方法在各种物体、光照和背景下始终能取得较高的成功率。第二行和第三行突显了在更多机会的情况下，其成功率甚至有可能进一步提高。




图 9 | 图 6 的完整未裁剪版本。



图 10 | 基于 Qwen-VL-Chat 的 DexGraspVLA 规划器做出的边界框预测。在各种光照和背景条件下，它都能准确地将语言指令与杂乱场景中的目标物体对应起来，并标记出正确的边界框。